Einführung in R - Erste Schritte der Daten Verarbeitung und Analyse

Jan-Philipp Kolb

13 Juni, 2019

Inhalt dieses Abschnitts

Was uns die Daten sagen.

- Wie bekommt man einen Überblick über die Daten
- Indizieren von Vektoren, Datensätzen und Listen
- Wie geht man mit fehlenden Werten um
- Zusammenhänge zwischen Variablen

- Beispieldaten importieren:

```
dat <- read.csv2("../data/wahldat_ffm.csv")
```

```
head(names(dat))
```

```
## [1] "X"                                  "Stadtteilnummer"
## [3] "Stadtteilname"                      "Wahlberechtigte.ohne
## [5] "Wahlberechtigte.mit.Sperrvermerk"   "Wahlberechtigte.insg
```

Anzahl Zeilen und Spalten

- Anzahl der Zeilen/Spalten ermitteln

```
nrow(dat) # Zeilen
```

```
## [1] 45
```

```
ncol(dat) # Spalten
```

```
## [1] 58
```

Die Daten ansehen

- Die ersten Zeilen sehen:

```
head(dat) # erste Zeilen
tail(dat) # letzte Zeilen
```

- Einen Überblick mit Rstudio bekommen:

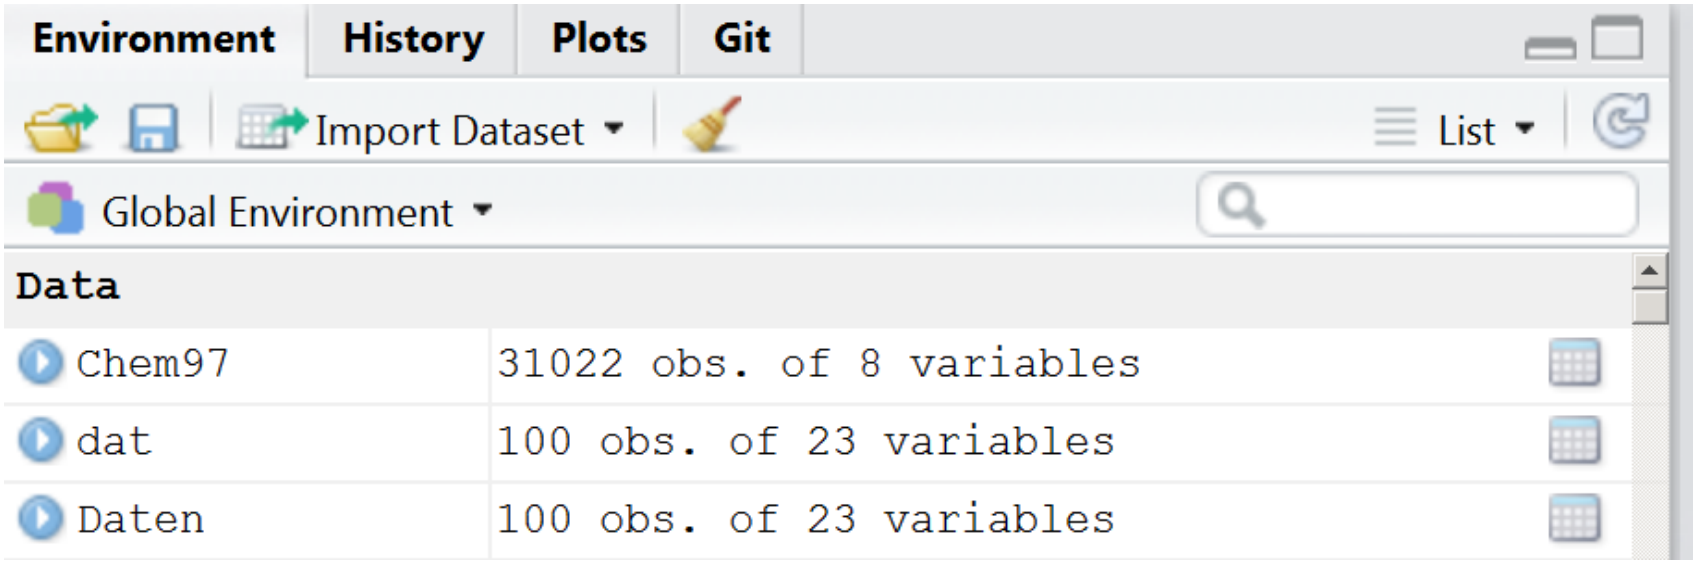


```
View(dat)
```

Indizierung eines data.frame

```
dat[1,1] # das Element oben links bekommen
```

```
## [1] 1
```

```
dat[2,] # nur die zweite Zeile sehen
```

```
##   X Stadtteilnummer Stadtteilname Wahlberechtigte.ohne.Sperrv
## 2 2                2    Innenstadt
```

```
dat[,1] # sich nur die erste Spalte anzeigen lassen
```

```
## [1] 1 2 3 4 5 6
```

Weitere Möglichkeiten zur Indizierung eines data.frame

```
dat[1:2,] # getting the first two rows
```

```
##   X Stadtteilnummer Stadtteilname Wahlberechtigte.ohne.Sperrv
## 1 1                1      Altstadt                            
## 2 2                2    Innenstadt                            
##   Wahlberechtigte.mit.Sperrvermerk Wahlberechtigte.insgesamt
## 1                              495                      2189
## 2                              653                      3049
##   Wahlbeteiligung darunter.Wähler.mit.Wahlschein
## 1            64.3                           473
## 2            55.6                           607
##   Anteil.Wähler.mit.Wahlschein
## 1                         33.6
## 2                         35.8
```

Indizierung

- Das Dollarzeichen kann auch zur Adressierung einzelner Spalten verwendet werden.

```
head(dat$Stadtteilname)
```

```
## [1] Altstadt     Innenstadt   Westend-Süd  Westend-Nord Norde
## [6] Nordend-Ost
## 45 Levels: Altstadt Bergen-Enkheim Berkersheim Bockenheim ...
```

```
dat$Stadtteilname[1:10]
```

```
##  [1] Altstadt                    Innenstadt
##  [3] Westend-Süd                 Westend-Nord
##  [5] Nordend-West                Nordend-Ost
##  [7] Ostend                      Bornheim
##  [9] Gutleut-/Bahnhofsviertel Gallus
## 45 Levels: Altstadt Bergen-Enkheim Berkersheim Bockenheim ...
```

Zugriff auf Spalten

- Wie bereits beschrieben, können Sie über Zahlen auf die Spalten zugreifen.

```
head(dat[,3])
```

```
## [1] Altstadt     Innenstadt   Westend-Süd  Westend-Nord Norde
## [6] Nordend-Ost
## 45 Levels: Altstadt Bergen-Enkheim Berkersheim Bockenheim ...
```

```
head(dat[,"Stadtteilname"]) # dasselbe Ergebnis
```

```
## [1] Altstadt     Innenstadt   Westend-Süd  Westend-Nord Norde
## [6] Nordend-Ost
## 45 Levels: Altstadt Bergen-Enkheim Berkersheim Bockenheim ...
```

Logische Operatoren

```
(a <- 1:7) # Beispieldaten - numerisch
```

```
## [1] 1 2 3 4 5 6 7
```

```
a>4
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE
```

```
a>=4
```

```
## [1] FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE
```

```
a<3
```

```
## [1]  TRUE  TRUE FALSE FALSE FALSE FALSE FALSE
```

Logische Operatoren II

```
(b <- letters[1:7]) # Beispieldaten - Strings
```

```
## [1] "a" "b" "c" "d" "e" "f" "g"
```

```
b=="e"
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE FALSE FALSE
```

```
b %in% c("e","f")
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE  TRUE FALSE
```

GESIS Panel Variable - Estimated duration (bazq020a)

Wie lange haben Sie den Fragebogen ausgefüllt?

```
wahlberechtigte <- as.numeric(dat$Wahlberechtigte.insgesamt)
```

```
summary(wahlberechtigte)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    2189    5723    9092   18609   11796  418703
```

Missing values

- Fehlende Werte sind in R als `NA` definiert

```
wahlberechtigte[5] <- NA
```

- Bei mathematische Funktionen gibt es in der Regel eine Möglichkeit, fehlende Werte auszuschließen.
- Bei `mean()`, `median()`, `colSums()`, `var()`, `sd()`, `min()` und `max()` gibt es das Argument `na.rm`.

```
mean(wahlberechtigte)
```

```
## [1] NA
```

```
mean(wahlberechtigte,na.rm=T)
```

```
## [1] 18588.25
```

Die fehlenden Werte finden

```
is.na(head(wahlberechtigte))
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE FALSE
```

```
which(is.na(wahlberechtigte))
```

```
## [1] 5
```

```
table(is.na(wahlberechtigte))
```

```
##
## FALSE  TRUE
##    44     1
```

Der Befehl complete.cases()

```
# Beispiel Datensatz
mydata <- data.frame(A=c(1,NA,9,6),B=c("A","B",1,NA))
```

- Der Befehl `complete.cases()` gibt einen logischen Vektor zurück, der angibt, welche Fälle vollständig sind.

```
# Datenzeilen mit fehlenden Werten auflisten
mydata[complete.cases(mydata),]
```

```
##   A B
## 1 1 A
## 3 9 1
```

Verschiedene Arten von fehlenden Werten (NAs) spezifizieren

- Spezifiziere verschiedene Arten von Fehlern mit dem Paket `memisc`.
- Benutze dazu den Befehl `include.missings()`

```
library(memisc)
```

```
?include.missings
```

- Es ist auch möglich, Codebuch-Einträge mit `memisc` zu erstellen.

```
codebook(dat$Wähler)
```

Kategoriale Variable einführen

```
dat$wb_kat <- cut(dat$Wahlbeteiligung,3)
head(dat$wb_kat)
```

```
## [1] (58.8,67.5] (50,58.8]   (67.5,76.3] (67.5,76.3] (67.5,76.
## Levels: (50,58.8] (58.8,67.5] (67.5,76.3]
```

```
levels(dat$wb_kat) <- c("niedrig","mittel","hoch")
head(dat$wb_kat)
```

```
## [1] mittel  niedrig hoch    hoch    hoch    hoch
## Levels: niedrig mittel hoch
```

Datensatz indizieren

```
table(dat$wb_kat)
```

```
##
## niedrig  mittel    hoch
##      14      16      15
```

```
dat[dat$wb_kat=="mittel","Stadtteilname"]
dat[dat$wb_kat!="mittel","Stadtteilname"]
```

Weitere wichtige Optionen

- Speichern des Ergebnisses in einem Objekt

```
subDat <- dat[dat$Wahlbeteiligung>65,]
```

- mehrere Bedingungen können mit & verknüpft werden

```
dat[dat$Anteil.DIE.LINKE>12 & dat$Anteil.GRÜNE>25,"Stadtteilname
```

- das oder das Argument - eine der beiden Bedingungen muss erfüllt sein

```
dat[dat$Anteil.CDU>28 | dat$Anteil.AfD>28,"Stadtteilname"]
```

Umbenennen der Spaltennamen

- Mit dem Befehl `colnames` erhält man die Spaltennamen

```
colnames(dat)
```

- Wir können die Spaltennamen umbenennen:

```
colnames(dat)[1] <- "Nummer"
```

- Das gleiche gilt für die Zeilennamen

```
rownames(dat)
```

Exkurs - Wie man Labels verwendet

Werkzeuge für das Arbeiten mit kategorischen Variablen (Faktoren)

```
library("forcats")
```

- `fct_collapse` - um Faktorstufen zu verdichten
- `fct_count` - um die Einträge in einem Faktor zu zählen
- `fct_drop` - Entferne unbenutzte Levels

Der Befehl fct_count

Freizeit Häufigkeit: Bücher lesen (a11c026a)

```
fct_count(f = dat$wbkat5)
```

```
## # A tibble: 5 x 2
##   f         n
##   <fct> <int>
## 1 1         5
## 2 2        12
## 3 3        11
## 4 4        10
## 5 5         7
```

Der Befehl fct_collapse

```
wbkat <- fct_collapse(.f = dat$wbkat5,
    hoch=c("4","5"))
```

```
fct_count(wbkat)
```

```
## # A tibble: 4 x 2
##   f          n
##   <fct> <int>
## 1 1          5
## 2 2         12
## 3 3         11
## 4 hoch      17
```

Die apply Familie

```
(ApplyDat <- cbind(1:4,runif(4),rnorm(4))) #Example
```

```
##      [,1]      [,2]       [,3]
## [1,]    1 0.2390422 -0.1321961
## [2,]    2 0.5771335 -0.9588695
## [3,]    3 0.3969883  0.7698575
## [4,]    4 0.1860148 -0.2416123
```

```
apply(ApplyDat,1,mean)
```

```
## [1] 0.3689487 0.5394213 1.3889486 1.3148009
```

```
apply(ApplyDat,2,mean)
```

```
## [1]  2.5000000  0.3497947 -0.1407051
```

Der Befehl apply()

```
apply(ApplyDat,1,var)
```

```
## [1] 0.3331238 2.1897938 1.9813728 5.4534371
```

```
apply(ApplyDat,1,sd)
```

```
## [1] 0.5771688 1.4797952 1.4076124 2.3352595
```

```
apply(X = ApplyDat,MARGIN = 1,FUN = range)
```

```
##             [,1]       [,2]      [,3]       [,4]
## [1,] -0.1321961 -0.9588695 0.3969883 -0.2416123
## [2,]  1.0000000  2.0000000 3.0000000  4.0000000
```

Die Argumente des Befehls `apply()`

- Wenn `MARGIN=1` wird die Funktion `mean` auf die Reihen angewendet,
- Wenn `MARGIN=2` wird die Funktion `mean` auf die Spalten angewendet,
- Anstatt `mean` kann man auch `var`, `sd` oder `length` verwenden.

Der Befehl tapply()

```
ApplyDat <- data.frame(Income=rnorm(5,1400,200),
                       Sex=sample(c(1,2),5,replace=T))
```

Beispiel Befehl tapply()

```
tapply(ApplyDat$Income,
       ApplyDat$Sex,function(x)x)
```

```
## $`1`
## [1] 1357.086 1464.046 1519.477 1210.560
##
## $`2`
## [1] 1690.203
```

- Andere Befehle können auch verwendet werden. . . .. auch selbst geschriebene

Übung - tapply() Befehl verwenden

- Erstellen Sie eine Variable `wbkat`, in der sie die Wahlbeteiligung in den Stadtteilen in fünf Kategorien einteilen.
- Berechnen Sie mit Hilfe des `tapply` Befehls den durchschnittlichen Anteil der AFD pro Wahlbeteiligungskategorie.

Edgar Anderson's Iris Datensatz

```
data(iris)
```

```
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width
## 1          5.1         3.5          1.4         0.2
## 2          4.9         3.0          1.4         0.2
## 3          4.7         3.2          1.3         0.2
## 4          4.6         3.1          1.5         0.2
## 5          5.0         3.6          1.4         0.2
## 6          5.4         3.9          1.7         0.4
```

- petal length and width - Länge und Breite der Blütenblätter
- sepal length and width - Kelchlänge und -breite
- **Wikipedia Artikel zum IRIS Datensatz**

Zusammenhang zwischen kontinuierlichen Variablen

```
# Pearson correlation coefficient
cor(iris$Sepal.Length,iris$Petal.Length)
```

```
## [1] 0.8717538
```

- Zusammenhang zwischen Blütenblattlänge und Blütenblattlänge ist 0,87
- Der Pearson-Korrelationskoeffizient ist die Standardmethode in `cor()`.

Verschiedene Korrelationskoeffizienten

```
# Pearson correlation coefficient
cor(iris[,1:4])
```

```
##                Sepal.Length Sepal.Width Petal.Length Petal.Widt
## Sepal.Length    1.0000000  -0.1175698    0.8717538   0.817941
## Sepal.Width    -0.1175698   1.0000000   -0.4284401  -0.366125
## Petal.Length    0.8717538  -0.4284401    1.0000000   0.962865
## Petal.Width     0.8179411  -0.3661259    0.9628654   1.000000
```

```
# Kendall's tau (rank correlation)
cor(iris[,1:4], method = "kendall")
```

```
##                Sepal.Length Sepal.Width Petal.Length Petal.Widt
## Sepal.Length   1.00000000 -0.07699679    0.7185159   0.655308
## Sepal.Width   -0.07699679  1.00000000   -0.1859944  -0.157125
## Petal.Length   0.71851593 -0.18599442    1.0000000   0.806890
## Petal.Width    0.65530856 -0.15712566    0.8068907   1.000000
```

```
# Spearman's rho (rank correlation)
cor(iris[,1:4], method = "spearman")
```

```
##                Sepal.Length Sepal.Width Petal.Length Petal.Widt
```

Eine zweidimensionale Kreuztabelle erstellen

Variablen

```
dat <- read.csv2("../data/bauenwohnen_teil.csv")
```

- Spiel100K - Wohnumfeld öffentlicher Raum - Spielplätze je 100 Kinder 2012
- baugenehm12 - Baugenehmigungen - Neue Ein/Zweifamilienhäuser 2012

Tabelle erstellen

```
tab <- table(dat$Spiel100K,dat$baugenehm12)
```

Kreuztabelle anschauen

Tabelle

```
##
##          mittel sehr viele sehr wenig
##   mittel      0           0          0
##   viele       0           0          0
##   wenig       1           1         11
```

Beziehung zwischen kategorialen Variablen

- `chisq.test()` prüft, ob zwei kategoriale Merkmale stochastisch unabhängig sind.
- Der Test wird gegen die Nullhypothese der Gleichverteilung durchgeführt.

```
chisq.test(tab)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab
## X-squared = NaN, df = 4, p-value = NA
```

Übung - eine interaktive Tabelle

- Laden Sie den Datensatz `bauenwohnen_teil.RData` vom **Github Verzeichnis** herunter.
- Importieren Sie den Datensatz in R
- Erstellen Sie eine interaktive Tabelle mit den folgenden Befehlen:

```
library(DT)
DT::datatable(dat)
```

- Probieren Sie witere Argumente der Funktion `datatable` aus.

Shiny App für eine schnelle explorative Datenanalyse

https://pharmacometrics.shinyapps.io/ggplotwithyourdata/

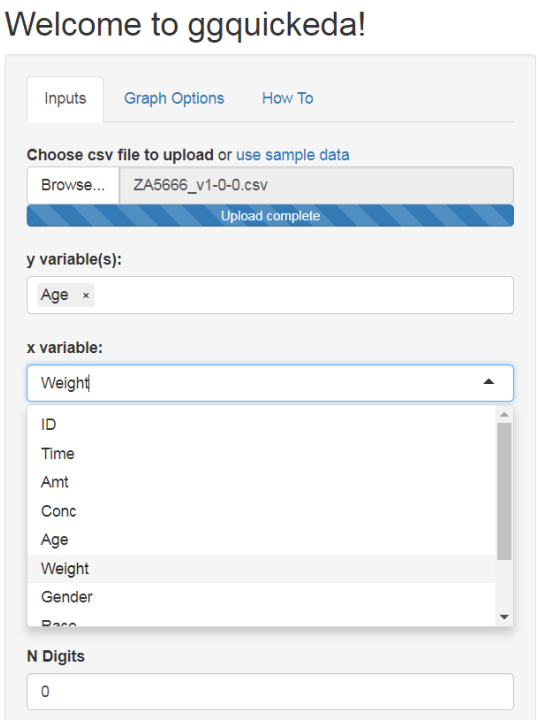

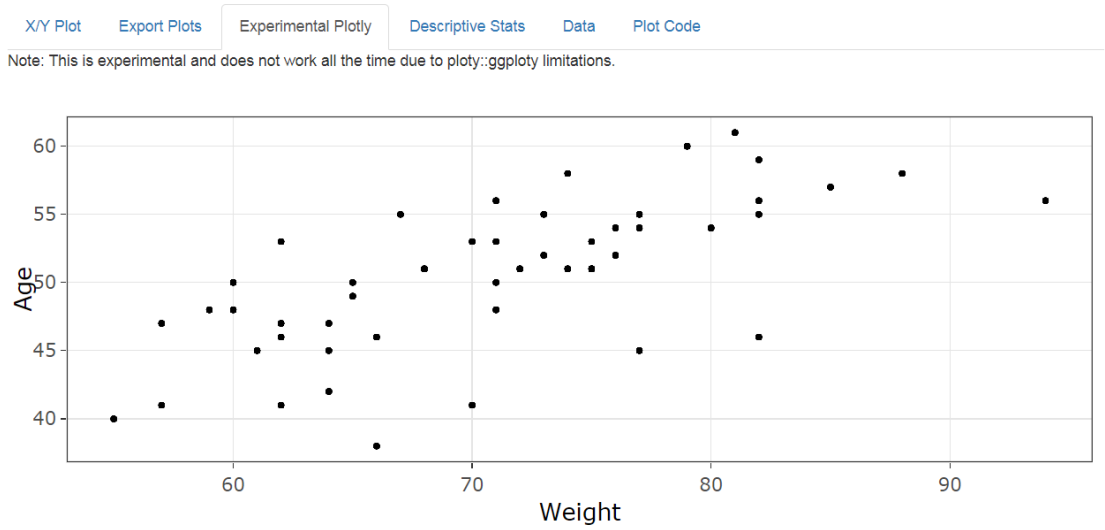

Weitere Links

- **Tidy data** - das Paket `tidyr`
- Homepage für: **the `tidyverse` collection**
- **Data wrangling mit R und RStudio**
- Hadley Wickham - **Tidy Data**
- Hadley Wickham - **Advanced R**
- Colin Gillespie and Robin Lovelace **Efficient R programming**